LIN3S

Causal Inference
Una “alternativa” al Test AB

Autor
Ubaldo Hervás

Fecha
marzo 2026

LIN3S

Conceptos básicos de Causal Inference

Autor
Ubaldo Hervás

Fecha
marzo 2026

Hablemos de causalidad

“We may define a cause to be an object, followed by another, [...] where if the first object had not been, the second never had existed”

– David Hume

Hablemos de causalidad

“We may define a cause to be an object, followed by another, [...] where if the first object had not been, the second never had existed”

– David Hume

Dos tipos de dependencia:

1. **Temporal:** La causa precede al efecto en el tiempo.
2. **Contrafactual:** Si la causa no hubiera ocurrido, el efecto tampoco.

Hablemos de causalidad

"We may define a cause to be an object, followed by another, [...] where if the first object had not been, the second never had existed"

– David Hume

Dos tipos de dependencia:

1. **Temporal:** La causa precede al efecto en el tiempo.
2. **Contrafactual:** Si la causa no hubiera ocurrido, el efecto tampoco.

Y(1) = Lo que el outcome sería (efecto) si hacemos algo (tratamiento).
Y(0) = Lo que el outcome hubiera sido (efecto) si no lo hubieras hecho (tratamiento).

El problema fundamental de la causalidad

Solo puedes observar uno de los outcomes potenciales, Y(1) o Y(0). Si el usuario hace algo (un click) observarás Y(1).

Nunca podrás calcular exactamente y con precisión la cantidad del contrafactual, el Y(0), pero puedes recrearla con una aproximación.

El problema fundamental de la causalidad

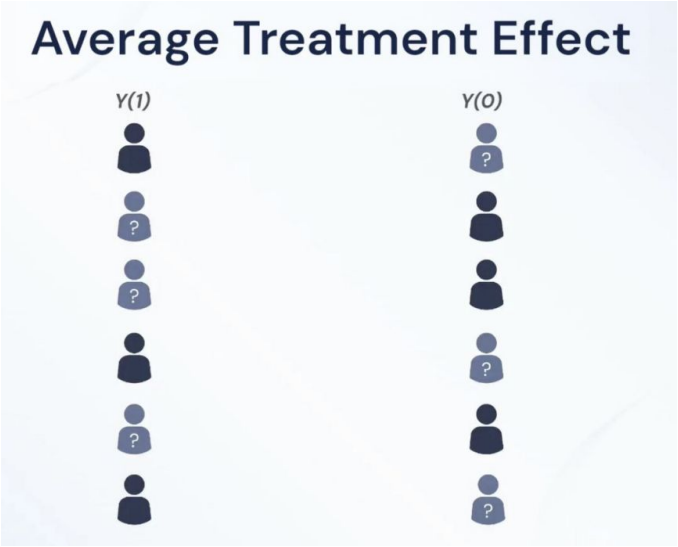

Nunca podrás observar ambos mundos.

Por cada usuario solo podemos ver Y(1) o Y(0): nunca ambos.

Causal Inference reemplaza el outcome que falta (?) con su valor esperado.

Esto permite aproximar el efecto del tratamiento (nuestra acción de marketing).

Y aquí entra el test AB

Cuando hacemos test AB, en esencia:

$E[Y|T=1] - E[Y|T=0]$

Como aleatorizamos... conseguimos algo fundamental: **balance de covariables.**

¿Qué significa eso? Significa que, bien hecho, el test AB (gracias a la randomización) permite eliminar "bias" y que, por lo tanto, **podamos establecer causalidad** si se cumplen sus assumptions más importantes:

- *Consistency*
- *No interference*
- *Exchangeability/Ignorability*

Cuando no podemos usar "experimental data" usaremos "observational data" (lo que vamos a ver a continuación).

¿Cuándo no se puede aplicar experimental data?

LIN3S

Pricing Experimentation
Three-market pricing

Autor
Ubaldo Hervás

Fecha
marzo 2026

¿Qué sucede con los proyectos de pricing management?

Los usuarios comparan entre sí

Las reseñas y el WOM propagan información sobre los precios.

El tratamiento de un usuario afecta el outcome de otros usuarios (introduce *bias*).

Riesgo reputacional

Mostrar precios diferentes a usuarios similares puede generar desconfianza y dañar la marca.

Efectos de largo plazo no capturados en experimentos cortos.

Podemos aplicar quasi-experimentos donde:

- Unos mercados reciben el tratamiento (el cambio en la política de precios)
- Otros sirven de control.

Aplicaremos **Synthetic Control Methods (SCM).**

Contexto

1. Una empresa de travel nos pide un análisis de la elasticidad del precio.

2. Para ello, se decide ejecutar tres experimentos con tres cantidades distintas en tres mercados distintos:
   a. +5%
   b. +10%
   c. +15%

3. **Hipótesis:** Subir el precio en un % determinado no tiene un efecto significativo en bookings/día.

DAG: Directed Acyclic Graphs

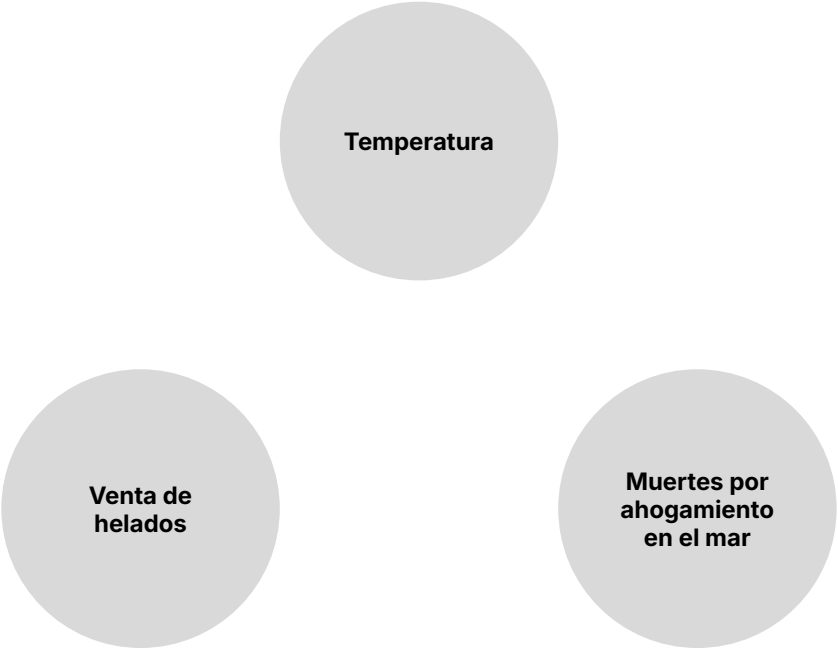

DAG: Directed Acyclic Graphs

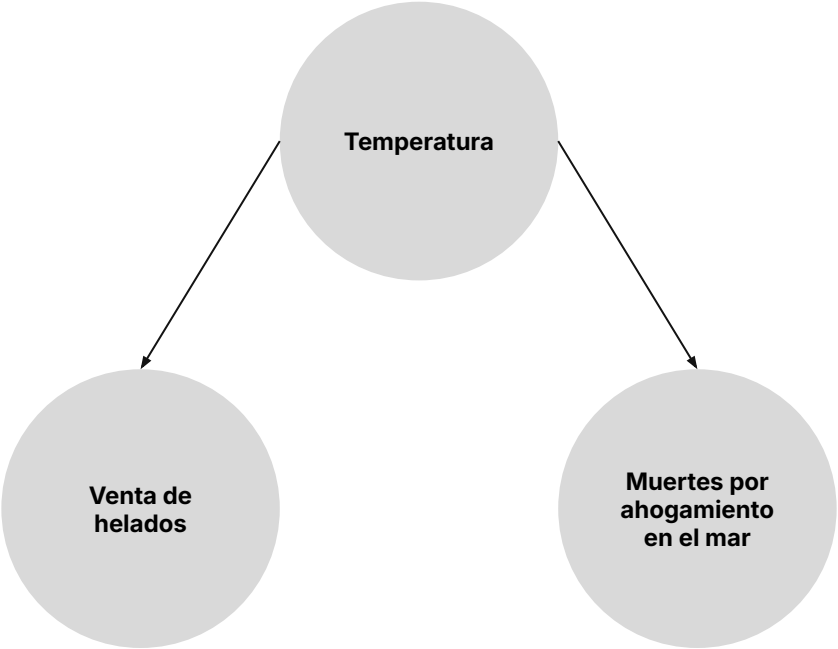

DAG: Directed Acyclic Graphs

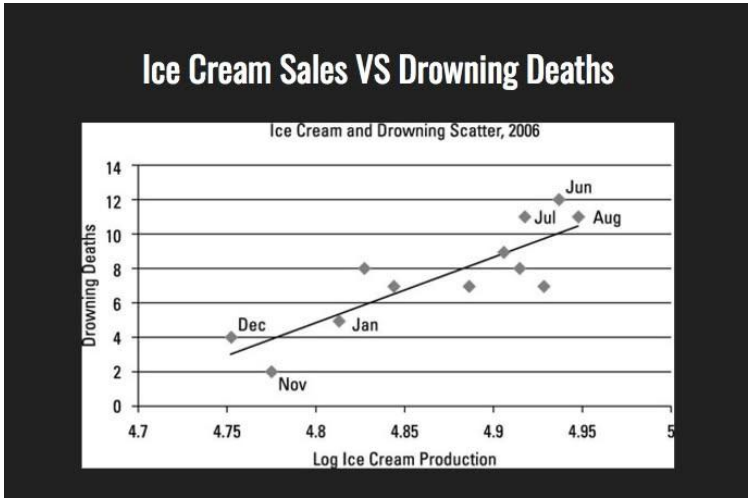

DAG: Directed Acyclic Graphs

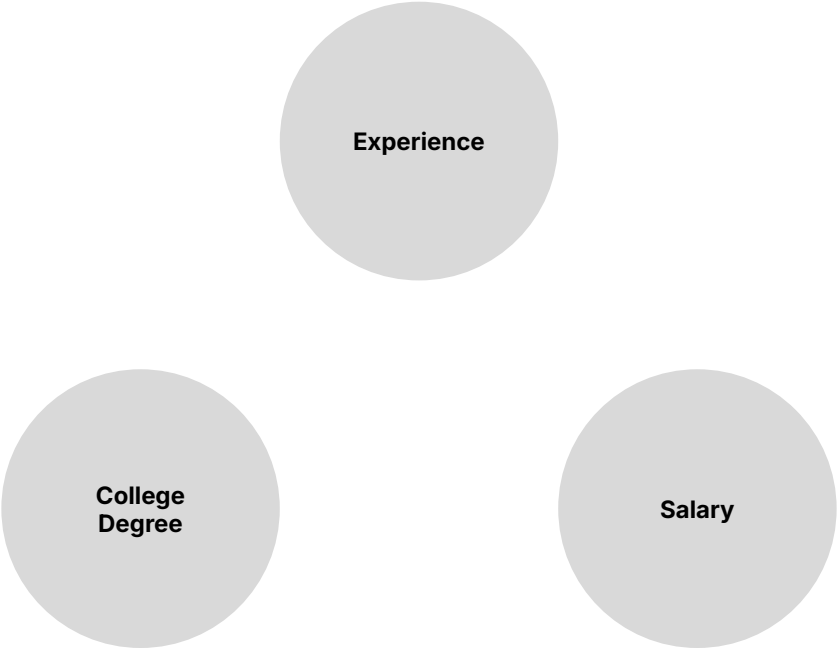

DAG: Directed Acyclic Graphs

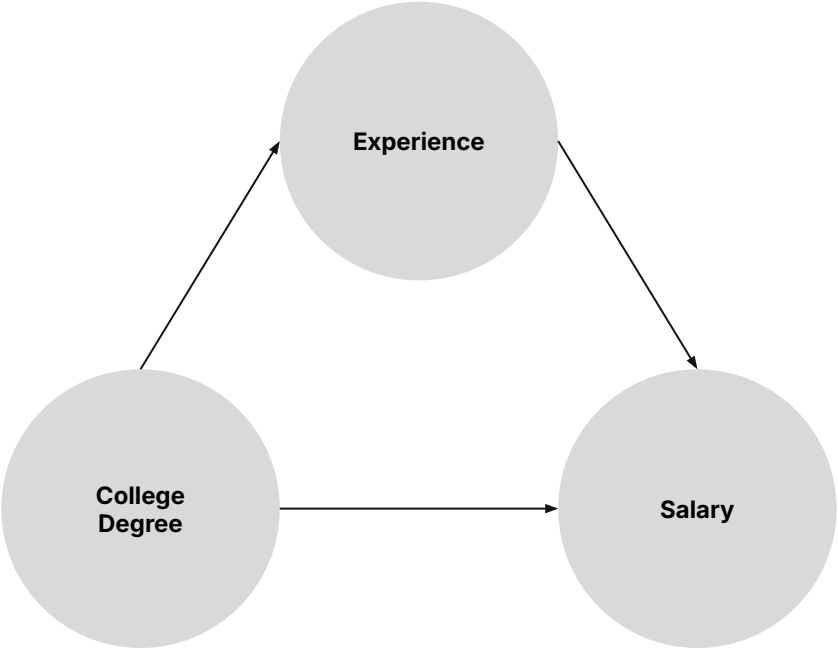

DAG: Directed Acyclic Graphs

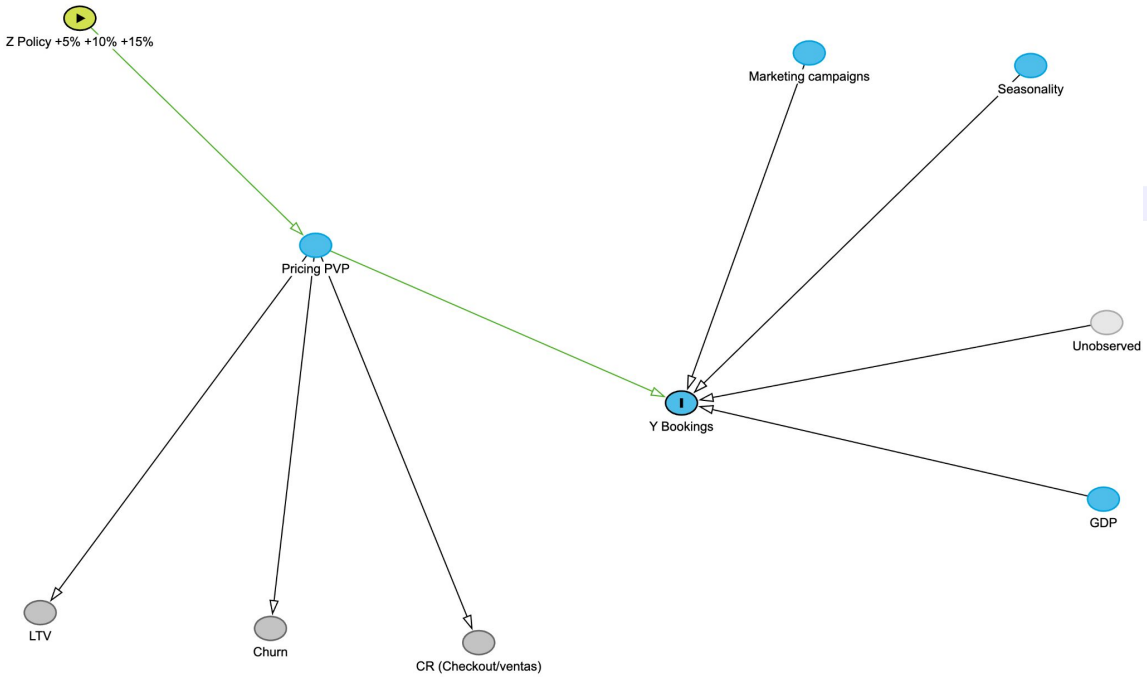

Causal effect identification

Adjustment (total effect)

Exposure: Z Policy +5% +10% +15%

Outcome: Y Bookings

No open biasing paths.

No adjustment is necessary to estimate the total effect of Z Policy +5% +10% +15% on Y Bookings.

Testable implications

The model implies the following conditional independences:

- Z Policy +5% +10% +15% ⊥ LTV | Pricing PVP
- Z Policy +5% +10% +15% ⊥ Churn | Pricing PVP
- Z Policy +5% +10% +15% ⊥ CR (Checkout/ventas) | Pricing PVP
- Z Policy +5% +10% +15% ⊥ Y Bookings | Pricing PVP
- Z Policy +5% +10% +15% ⊥ Marketing campaigns
- Z Policy +5% +10% +15% ⊥ Seasonality
- Z Policy +5% +10% +15% ⊥ GDP
- Pricing PVP ⊥ Marketing campaigns
- Pricing PVP ⊥ Seasonality

DAG: Directed Acyclic Graphs

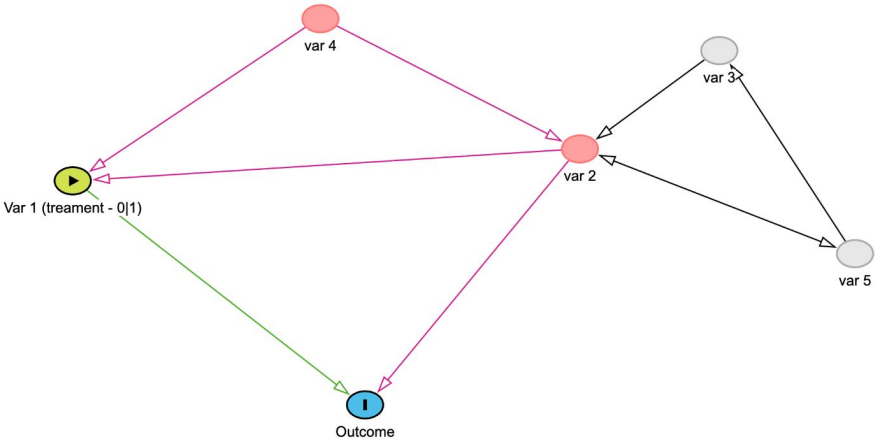

Causal effect identification

Adjustment (total effect)

Exposure: Var 1 (treament - 0|1)

Outcome: Outcome

Biasing paths are open.

Minimal sufficient adjustment sets for estimating the total effect of Var 1 (treament - 0|1) on Outcome:

- var 2

Testable implications

The model implies the following conditional independences:

- Outcome ⊥ var 4 | Var 1 (treament - 0|1), var 2

Model code

```
dag {
"Var 1 (treament - 0|1)"
[exposure,pos="-1.836,-0.887"
]
"var 2" [pos="-0.340,-1.028"]
"var 3"
[latent,pos="0.072,-1.460"]
"var 4" [pos="-1.105,-1.601"]
"var 5"
[latent,pos="0.472,-0.567"]
```

Summary

exposure(s)	**Var 1 (treament - 0|1)**
outcome(s)	**Outcome**
covariates	**4**
causal paths	**1**

DAG: Directed Acyclic Graphs

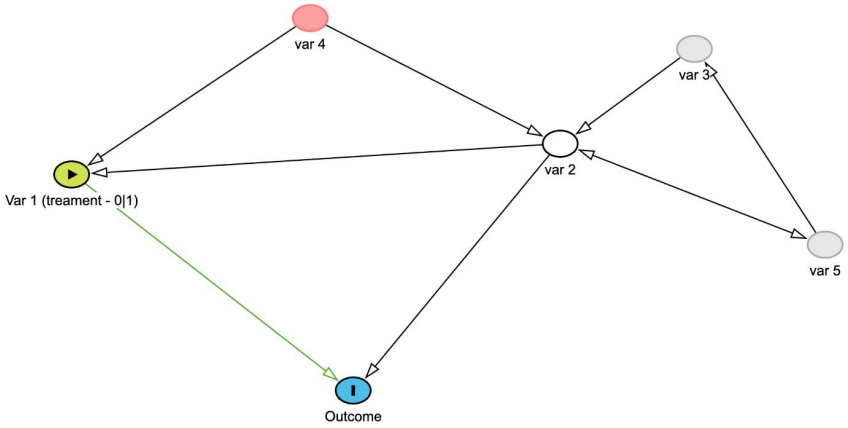

Causal effect identification

Adjustment (total effect)

Exposure: Var 1 (treament -

ne: Outcome
d: var 2
tly adjusted.
l sufficient adjustment
ntaining var 2 for
ing the total effect of Var
ment - 0|1) on Outcome:

r 2

able implications

odel implies the following
onal independences:

ome ⊥ var 4 | Var 1
ment - 0|1), var 2

el code

```
(treament - 0|1)"
re,pos="-1.836,-0.887"

ed,pos="-0.340,-1.028"

,pos="0.072,-1.460"]
 [pos="-1.105,-1.601"]
```

mary

exposure(s)	**Var 1 (treament - 0|1)**
outcome(s)	**Outcome**
covariates	**4**
causal paths	**1**

¿Qué ha pasado?

Situación: Comparamos tratados vs. no tratados que tengan el mismo valor de Var 2, para aislar el efecto causal de Var 1 (eso es ajustar por var2).

Ejemplo: Si treatment = 1 es tener programa de loyalty y treatment = 0 es no tenerlo, Var 2 podría ser **frecuencia de compra previa** (los clientes que ya compran mucho se apuntan más al programa (Var 2 → Var 1) y además compran más en el futuro independientemente del programa (Var 2 → Outcome).

Ajustar significa comparar el outcome de clientes con loyalty vs. sin loyalty **que tenían la misma frecuencia de compra previa**, para que la diferencia que observes no esté contaminada por el hecho de que los del programa ya eran mejores clientes de base.

Pero volvemos a nuestro caso...

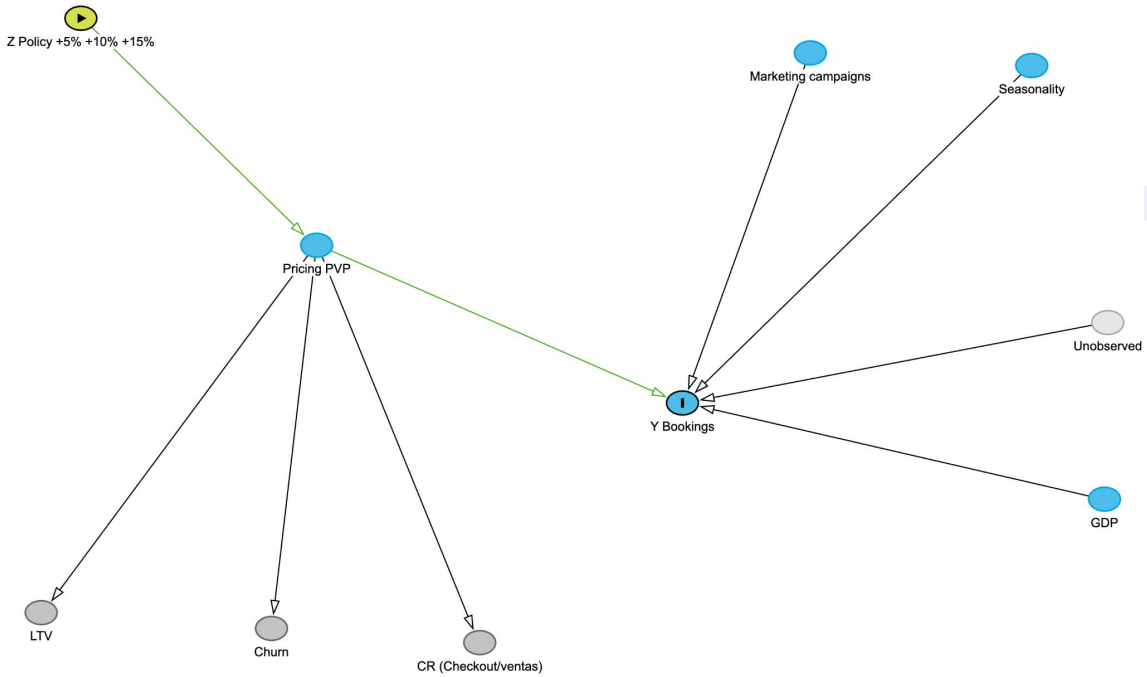

Causal effect identification

Adjustment (total effect)

Exposure: Z Policy +5% +10% +15%

Outcome: Y Bookings

No open biasing paths.

No adjustment is necessary to estimate the total effect of Z Policy +5% +10% +15% on Y Bookings.

Testable implications

The model implies the following conditional independences:

- Z Policy +5% +10% +15% ⊥ LTV | Pricing PVP
- Z Policy +5% +10% +15% ⊥ Churn | Pricing PVP
- Z Policy +5% +10% +15% ⊥ CR (Checkout/ventas) | Pricing PVP
- Z Policy +5% +10% +15% ⊥ Y Bookings | Pricing PVP
- Z Policy +5% +10% +15% ⊥ Marketing campaigns
- Z Policy +5% +10% +15% ⊥ Seasonality
- Z Policy +5% +10% +15% ⊥ GDP
- Pricing PVP ⊥ Marketing campaigns
- Pricing PVP ⊥ Seasonality

Asumimos:

- No hay un anuncio de cambio de pricing y no-interferencia entre mercados.

- Tratamos a nivel de mercado (no usuario) para evitar problemas de percepción de marca e interferencia dentro del mercado.

- Construimos un contrafactual sintético con mercados no tratados, es decir, **identificamos por match con el periodo pre-tratamiento de otros mercados, no por ajuste de confounders.**

- Wave 1 (+5%): ES - día 91
- Wave 2 (+10%): UK - día 106
- Wave 3 (+15%): PT - día 121

Acceso a datos a consecuencia del DAG

date	market	treatment_arm	wave	treatment_start	day_index	post	days_since_tre	base_price_eur	price_uplift_pct	price_eur	currency	fx_rate	price_local
2024-01-01	AT	control	0	0	1	0	0	89	0	89	EUR	0.9974	88.77
2024-01-02	AT	control	0	0	2	0	0	89	0	89	EUR	1.0088	89.79
2024-01-03	AT	control	0	0	3	0	0	89	0	89	EUR	1.0211	90.88
2024-01-04	AT	control	0	0	4	0	0	89	0	89	EUR	0.9968	88.71
2024-01-05	AT	control	0	0	5	0	0	89	0	89	EUR	0.9965	88.69
2024-01-06	AT	control	0	0	6	0	0	89	0	89	EUR	0.994	88.46
2024-01-07	AT	control	0	0	7	0	0	89	0	89	EUR	0.9995	88.95
2024-01-08	AT	control	0	0	8	0	0	89	0	89	EUR	1.0093	89.83
2024-01-09	AT	control	0	0	9	0	0	89	0	89	EUR	0.9968	88.72
2024-01-10	AT	control	0	0	10	0	0	89	0	89	EUR	0.9957	88.62
2024-01-11	AT	control	0	0	11	0	0	89	0	89	EUR	1.0006	89.05
2024-01-12	AT	control	0	0	12	0	0	89	0	89	EUR	0.9945	88.51
2024-01-13	AT	control	0	0	13	0	0	89	0	89	EUR	0.9955	88.6
2024-01-14	AT	control	0	0	14	0	0	89	0	89	EUR	0.9909	88.19
2024-01-15	AT	control	0	0	15	0	0	89	0	89	EUR	0.9952	88.58
2024-01-16	AT	control	0	0	16	0	0	89	0	89	EUR	1.003	89.26
2024-01-17	AT	control	0	0	17	0	0	89	0	89	EUR	0.996	88.64
2024-01-18	AT	control	0	0	18	0	0	89	0	89	EUR	0.9921	88.29
2024-01-19	AT	control	0	0	19	0	0	89	0	89	EUR	0.9926	88.34
2024-01-20	AT	control	0	0	20	0	0	89	0	89	EUR	1.0105	89.93
2024-01-21	AT	control	0	0	21	0	0	89	0	89	EUR	0.9995	88.95
2024-01-22	AT	control	0	0	22	0	0	89	0	89	EUR	0.9964	88.68
2024-01-23	AT	control	0	0	23	0	0	89	0	89	EUR	0.9994	88.95
2024-01-24	AT	control	0	0	24	0	0	89	0	89	EUR	0.9862	87.77
2024-01-25	AT	control	0	0	25	0	0	89	0	89	EUR	0.9998	88.99

1. Contexto

Pregunta a responder: ¿Cuánto cambió el consumo de reservas en los mercados donde aumentamos el precio +5%/+10%/+15%, comparado con lo que hubiera ocurrido si no hubiéramos cambiado el precio?

- ATT_5% = E[Y(1) - Y(0) | Z = +5%]
- ATT_10% = E[Y(1) - Y(0) | Z = +10%]
- ATT_15% = E[Y(1) - Y(0) | Z = +15%]

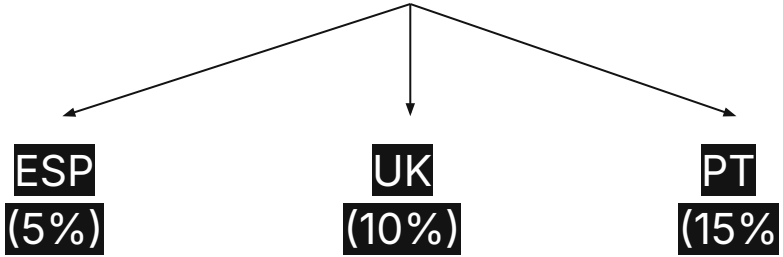

2. Mercados seleccionados

1. Con SCM no comparamos un mercado tratado con otro.

2. Comparamos **un mercado tratado Vs** un mercado sintético construido a partir de **otra serie de mercados (Donor Pool) que harán el papel de control.**

3. Combinaremos algunos de los mercados del Donor Pool para construir un contrafactual que muestre Y[0].

Así, podremos entender el efecto del cambio de pricing.

Estructura del experimento:

market	treatment_arm	treatment_start_day	wave	bookings
AT	control	0	0	129.206667
BE	control	0	0	162.086667
BG	control	0	0	101.320000
CH	control	0	0	187.906667
CZ	control	0	0	187.806667
DE	control	0	0	548.400000
DK	control	0	0	518.193333
ES	+5%	91	1	436.333333
FI	control	0	0	356.800000
FR	control	0	0	492.793333
GR	control	0	0	210.026667
HR	control	0	0	155.240000
HU	control	0	0	173.573333
IE	control	0	0	396.433333
IT	control	0	0	410.080000
LT	control	0	0	106.820000
LU	control	0	0	129.440000
NL	control	0	0	217.226667
NO	control	0	0	417.673333
PL	control	0	0	173.066667
PT	+15%	121	3	150.406667
RO	control	0	0	212.946667
SE	control	0	0	480.020000
SI	control	0	0	147.146667
SK	control	0	0	128.100000
UK	+10%	106	2	522.180000

3. ¿Se ha aplicado correctamente el tratamiento?

```
VERIFICACIÓN FIRST STAGE: Z → P
==================================================

ES (+5%):
  Precio pre:  89.00 EUR
  Precio post: 93.45 EUR
  Uplift nominal: 5.0%
  Uplift realizado: 5.0%
  Compliance: ✓ EXACTA (desviación 0.000pp)

UK (+10%):
  Precio pre:  89.00 EUR
  Precio post: 97.90 EUR
  Uplift nominal: 10.0%
  Uplift realizado: 10.0%
  Compliance: ✓ EXACTA (desviación 0.000pp)

PT (+15%):
  Precio pre:  89.00 EUR
  Precio post: 102.35 EUR
  Uplift nominal: 15.0%
  Uplift realizado: 15.0%
  Compliance: ✓ EXACTA (desviación 0.000pp)
```

¿Cómo vamos a construir los contrafactuales?

Técnica: SCM

SCM (Synthetic Control Methods) construye un grupo de control sintético de los mercados tratados.

Recordemos, son 3 tests:
- ES: +5%
- UK: +10%
- PT: +15%

¿Cómo se construye?

Combinamos varios mercados de forma ponderada.

¿Qué se busca?

Los pesos se ajustan para que el control sintético replique al mercado tratado antes de la subida de precio.

El modelo decide **cuánto importa cada variable** ¿pesa más que los bookings históricos se parezcan o que el GDP se parezca, o que el marketing spend se parezca? Eso son los V-weights.

Dado eso, busca **los pesos de los mercados que minimizan la diferencia pre-tratamiento.**

4. Ponderación - España (+5%)

```
RMSPE pre-periodo: 16.97
Pesos del sintético:
  CZ: 0.137
  DE: 0.490
  DK: 0.015
  FR: 0.123
  IE: 0.030
  NO: 0.069
  SE: 0.049
  SK: 0.085
Diagnóstico Positivity:
  Donors efectivos: 5/23
  HHI (concentración): 0.289 ✓
Importancia covariables (V, cross-validated):
  marketing_spend     : 0.558 ▓▓▓▓▓▓▓▓▓▓▓▓▓▓▓▓
  bookings_trend      : 0.343 ▓▓▓▓▓▓▓▓▓▓▓▓
  gdp_per_capita      : 0.069 ▓▓
  sessions            : 0.024
  bookings_mean       : 0.004
  weekend_ratio       : 0.002
Cross-validation V-weights:
  Split: 62 train / 28 val
  Val RMSPE (best): 15.23
  Val RMSPE range: 15.23 – 15.24 (variación 0.01%)
  V-sensitivity: V tiene impacto mínimo (landscape plano)
  → El resultado está dominado por la serie temporal, no por las covariables
Covariate Balance (DAG-guided):
  Covariable              Tratado  Sintético      SMD
  ------------------------------------------------------
  bookings_mean             433.2      433.0   +0.001     ✓
  bookings_trend              0.2        0.2   +0.558     ⚠️
  weekend_ratio               1.1        1.1   +0.123     ✓
  sessions                13653.9    13648.2   +0.001     ✓
  gdp_per_capita          30000.0    45785.5   -0.583     ⚠️
  marketing_spend           161.1      136.4   +0.555     ⚠️
  ⚠️ Desbalance en alguna covariable
```

- Para cada mercado, el modelo busca qué combinación de mercados de control se para más a él ANTES de subir el precio.

- En este caso, el control sintético de España es:
  - Alemania en un 49%
  - Francia en un 12%
  - Chequia un 14%
  - ...

- ¿Qué significa RMSPE? Es la diferencia entre España y su sintético pre-periodo. Un 16.97 significa que **se desvía de media 17 bookings/día.**

4. Ponderación - España (+5%)

```
RMSPE pre-periodo: 16.97
Pesos del sintético:
  CZ: 0.137
  DE: 0.490
  DK: 0.015
  FR: 0.123
  IE: 0.030
  NO: 0.069
  SE: 0.049
  SK: 0.085
Diagnóstico Positivity:
  Donors efectivos: 5/23
  HHI (concentración): 0.289 ✓
Importancia covariables (V, cross-validated):
  marketing_spend     : 0.558 ▓▓▓▓▓▓▓▓▓▓▓▓▓▓▓▓
  bookings_trend      : 0.343 ▓▓▓▓▓▓▓▓▓▓▓▓
  gdp_per_capita      : 0.069 ▓▓
  sessions            : 0.024
  bookings_mean       : 0.004
  weekend_ratio       : 0.002
Cross-validation V-weights:
  Split: 62 train / 28 val
  Val RMSPE (best): 15.23
  Val RMSPE range: 15.23 – 15.24 (variación 0.01%)
  V-sensitivity: V tiene impacto mínimo (landscape plano)
  → El resultado está dominado por la serie temporal, no por las covariables
Covariate Balance (DAG-guided):
  Covariable              Tratado  Sintético      SMD
  ----------------------------------------------------
  bookings_mean             433.2      433.0   +0.001     ✓
  bookings_trend              0.2        0.2   +0.558    ⚠️
  weekend_ratio               1.1        1.1   +0.123     ✓
  sessions                13653.9    13648.2   +0.001     ✓
  gdp_per_capita          30000.0    45785.5   -0.583    ⚠️
  marketing_spend           161.1      136.4   +0.555    ⚠️
  ⚠️ Desbalance en alguna covariable
```

- **Positivity:** el donante no depende de unos pocos. Son 8 mercados en total con peso superior a 0. Los donors efectivos son considerados los superiores a 5%. De los 23 mercados de control disponibles, 5 contribuyen de forma relevante al grupo de control.

- **HHI:** es la suma de los pesos al cuadrado. **Un valor de 0.289 significa que está bien distribuido** ya que está más cerca de 0 pero no es ultra-pequeño. La interpretación es que Alemania pesa mucho pero los otros pequeños compensan.
  - HHI va de 0 a 1:
    - 1 = Máxima concentración de mercados
    - 0 = Mínima concentración de mercados

4. Ponderación - España (+5%)

```
RMSPE pre-periodo: 16.97
Pesos del sintético:
  CZ: 0.137
  DE: 0.490
  DK: 0.015
  FR: 0.123
  IE: 0.030
  NO: 0.069
  SE: 0.049
  SK: 0.085
Diagnóstico Positivity:
  Donors efectivos: 5/23
  HHI (concentración): 0.289 ✓
Importancia covariables (V, cross-validated):
  marketing_spend     : 0.558 ▓▓▓▓▓▓▓▓▓▓▓▓▓▓▓▓
  bookings_trend      : 0.343 ▓▓▓▓▓▓▓▓▓▓
  gdp_per_capita      : 0.069 ▓▓
  sessions            : 0.024
  bookings_mean       : 0.004
  weekend_ratio       : 0.002
Cross-validation V-weights:
  Split: 62 train / 28 val
  Val RMSPE (best): 15.23
  Val RMSPE range: 15.23 – 15.24 (variación 0.01%)
  V-sensitivity: V tiene impacto mínimo (landscape plano)
  → El resultado está dominado por la serie temporal, no por las covariables
Covariate Balance (DAG-guided):
  Covariable              Tratado  Sintético      SMD
  ------------------------------------------------------
  bookings_mean             433.2      433.0   +0.001     ✓
  bookings_trend              0.2        0.2   +0.558     ⚠️
  weekend_ratio               1.1        1.1   +0.123     ✓
  sessions                13653.9    13648.2   +0.001     ✓
  gdp_per_capita          30000.0    45785.5   -0.583     ⚠️
  marketing_spend           161.1      136.4   +0.555     ⚠️
  ⚠️ Desbalance en alguna covariable
```

- **¿Os acordáis de las covariables del DAG?** Hay un sistema más allá de lo que podamos hacer en pricing y demás...
  - ¿Cuánto peso le da el modelo a cada variable que hemos incluido en el DAG?
    - Vemos que marketing_spend o bookings_trend pesa mucho, pero...

4. Ponderación - España (+5%)

```
RMSPE pre-periodo: 16.97
Pesos del sintético:
  CZ: 0.137
  DE: 0.490
  DK: 0.015
  FR: 0.123
  IE: 0.030
  NO: 0.069
  SE: 0.049
  SK: 0.085
Diagnóstico Positivity:
  Donors efectivos: 5/23
  HHI (concentración): 0.289 ✓
Importancia covariables (V, cross-validated):
  marketing_spend     : 0.558 ▓▓▓▓▓▓▓▓▓▓▓▓▓▓▓▓
  bookings_trend      : 0.343 ▓▓▓▓▓▓▓▓▓▓▓▓
  gdp_per_capita      : 0.069 ▓▓
  sessions            : 0.024
  bookings_mean       : 0.004
  weekend_ratio       : 0.002
Cross-validation V-weights:
  Split: 62 train / 28 val
  Val RMSPE (best): 15.23
  Val RMSPE range: 15.23 – 15.24 (variación 0.01%)
  V-sensitivity: V tiene impacto mínimo (landscape plano)
  → El resultado está dominado por la serie temporal, no por las covariables
Covariate Balance (DAG-guided):
  Covariable              Tratado  Sintético      SMD
  ------------------------------------------------------
  bookings_mean             433.2      433.0   +0.001     ✓
  bookings_trend              0.2        0.2   +0.558     ⚠
  weekend_ratio               1.1        1.1   +0.123     ✓
  sessions                13653.9    13648.2   +0.001     ✓
  gdp_per_capita          30000.0    45785.5   -0.583     ⚠
  marketing_spend           161.1      136.4   +0.555     ⚠
  ⚠ Desbalance en alguna covariable
```

- **¿Cuán relevantes son las covariables en este caso?**
  - **En España, poco:** probamos 101 repartos distintos de importancia y el error varía un 0.01% (de 15.23 a 15.24).
    - ¿En qué se basa este reparto? Usamos V-weights (Abadie, 2010) el cual se basa en **aplicar diversos pesos (uniformes, aleatorios...)** y evaluar la diferencia.
    - En este caso es mínima (0.01).
      - ¿Que significa esto? Pues que las covariables no pesan tanto como cabría esperar en España.

4. Ponderación - España (+5%)

```
RMSPE pre-periodo: 16.97
Pesos del sintético:
  CZ: 0.137
  DE: 0.490
  DK: 0.015
  FR: 0.123
  IE: 0.030
  NO: 0.069
  SE: 0.049
  SK: 0.085
Diagnóstico Positivity:
  Donors efectivos: 5/23
  HHI (concentración): 0.289 ✓
Importancia covariables (V, cross-validated):
  marketing_spend     : 0.558 ▓▓▓▓▓▓▓▓▓▓▓▓▓▓▓▓
  bookings_trend      : 0.343 ▓▓▓▓▓▓▓▓▓▓▓▓
  gdp_per_capita      : 0.069 ▓▓
  sessions            : 0.024
  bookings_mean       : 0.004
  weekend_ratio       : 0.002
Cross-validation V-weights:
  Split: 62 train / 28 val
  Val RMSPE (best): 15.23
  Val RMSPE range: 15.23 – 15.24 (variación 0.01%)
  V-sensitivity: V tiene impacto mínimo (landscape plano)
  → El resultado está dominado por la serie temporal, no por las covariables
Covariate Balance (DAG-guided):
  Covariable              Tratado  Sintético      SMD
  ----------------------------------------------------
  bookings_mean             433.2      433.0   +0.001     ✓
  bookings_trend              0.2        0.2   +0.558     ⚠️
  weekend_ratio               1.1        1.1   +0.123     ✓
  sessions                13653.9    13648.2   +0.001     ✓
  gdp_per_capita          30000.0    45785.5   -0.583     ⚠️
  marketing_spend           161.1      136.4   +0.555     ⚠️
  ⚠️ Desbalance en alguna covariable
```

- **¿El grupo de control se parece a las características estructurales de la variante?**
  - Bookings_mean ✅
  - Bookings_trend ⚠️
  - Weekend_ratio ✅
  - Sessions ✅
  - Gdp_per_capita ⚠️
    - Es superior porque Alemania pesa un 0.49. Esto no es necesariamente malo.
  - Marketing spend ⚠️

4. Ponderación - UK (+10%)

```
RMSPE pre-periodo: 31.39
Pesos del sintético:
  DE: 0.718
  DK: 0.048
  FR: 0.234
Diagnóstico Positivity:
  Donors efectivos: 2/23
  HHI (concentración): 0.573 ⚠️ Alta concentración
Importancia covariables (V, cross-validated):
  bookings_trend      : 0.509 ▇▇▇▇▇▇▇▇▇▇▇▇▇▇▇▇
  sessions            : 0.136 ▇▇▇▇
  bookings_mean       : 0.116 ▇▇▇
  marketing_spend     : 0.112 ▇▇▇
  gdp_per_capita      : 0.085 ▇▇
  weekend_ratio       : 0.042 ▇
Cross-validation V-weights:
  Split: 73 train / 32 val
  Val RMSPE (best): 45.41
  Val RMSPE range: 45.41 - 45.43 (variación 0.01%)
  V-sensitivity: V tiene impacto mínimo (landscape plano)
  → El resultado está dominado por la serie temporal, no por las covariables
Covariate Balance (DAG-guided):
  Covariable              Tratado  Sintético      SMD
  ---------------------------------------------------------
  bookings_mean             530.1      527.8   +0.016     ✓
  bookings_trend              0.6        0.3   +2.452    ⚠️
  weekend_ratio               1.1        1.1   -0.018     ✓
  sessions                16518.8    16702.6   -0.040     ✓
  gdp_per_capita          45000.0    47165.8   -0.080     ✓
  marketing_spend           194.0      186.5   +0.168     ✓
  ⚠️ Desbalance en alguna covariable
```

- RMSPE: Desviación de 31.39 booking/dia
- Formado por:
  - Alemania: 71.8%
  - Francia: 23,4%
  - Dinamarca: 4,8%

Aquí hay una problema a resolver: Si Alemania como mercado en el post-intervención tiene una particularidad a nivel de consumo arrastrará nuestro control sintético porque está sobrerrepresentado.

Solución: Como no me puedo fiar del método, utilizo un segundo completamente distinto: **Bayesian Structured Time Series (BSTS).**

4. Ponderación - UK (+10%) - BSTS

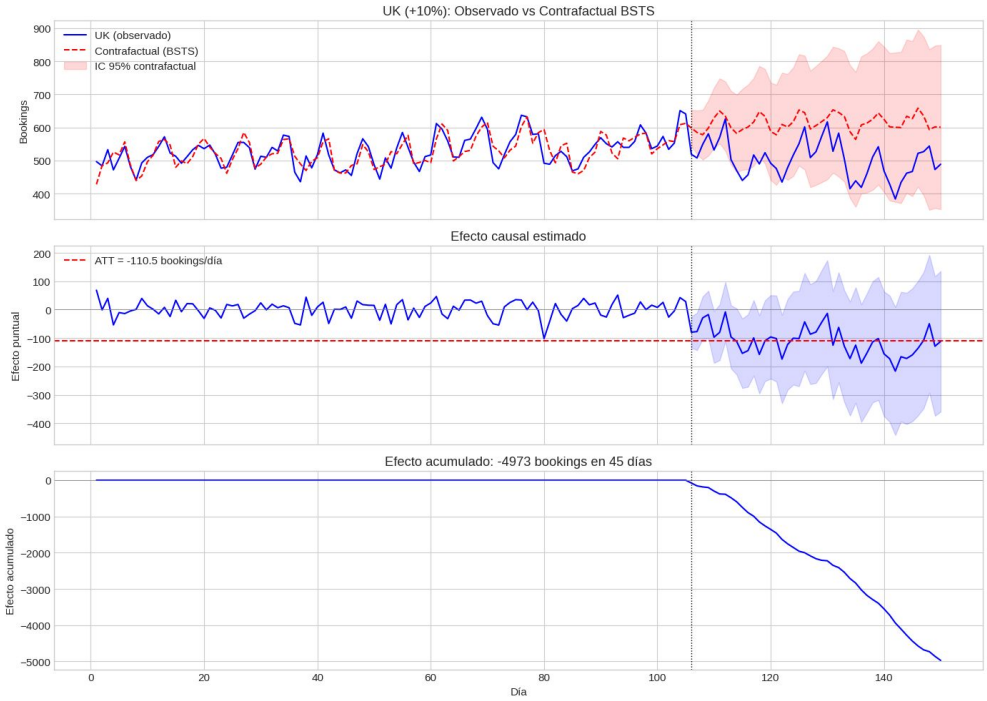

1. La línea roja (contrafactual): lo que habría pasado sin subir precio según BSTS. A partir del tratamiento
2. La línea azul (factual): cae por debajo. La banda rosa es la incertidumbre.

3. **El efecto puntual** (diferencia entre factual y contrafactual) día a día. La mayoría de días por debajo de cero, ergo, la subida reduce demanda.
4. **Efecto acumulado:** en 45 días se pierden alrededor de 5.000 reservas.

4. Ponderación - UK (+10%) - BSTS

```
======================================================================
COMPARACIÓN: SCM vs BSTS para UK (+10%)
======================================================================

  SCM:  ATT = -44.6 bookings/día
        HHI = 0.573 ⚠️
        RMSPE = 31.4

  BSTS: ATT = -110.5 bookings/día
        IC 95% = [-282.0, 60.9]

  Diagnóstico de concordancia:
    Misma dirección:          ✓
    SCM dentro del IC BSTS:   ✓
    Ratio de magnitud:        2.5x ⚠️
```

- **SCM:** -45 reservas/día (luego lo veremos)
- **BSTS:** -110 reservas/día

No coinciden exactamente, pero:

- Misma dirección
- SCM cae dentro del intervalo de confianza del BSTS (aunque el IC de BSTS es positivo...)
- Ratio de magnitud: BSTS estima x2.5 veces más caida que SCM.

El intervalo de confianza de BSTS incluye 0... Pero el SCM validado con Placebos (más tarde lo veremos) sí excluye 0. Los usamos juntos: el SCM da la precisión el BSTS confirma la dirección con un método independiente.

4. Ponderación - PT (+15%)

```
RMSPE pre-periodo: 10.76
Pesos del sintético:
  AT: 0.393
  BE: 0.329
  CZ: 0.033
  FR: 0.029
  LT: 0.117
  LU: 0.051
  NL: 0.012
  SK: 0.018
Diagnóstico Positivity:
  Donors efectivos: 4/23
  HHI (concentración): 0.281 ✓
Importancia covariables (V, cross-validated):
  bookings_trend      : 0.509 ▇▇▇▇▇▇▇▇▇▇▇▇▇▇▇▇
  sessions            : 0.136 ▇▇▇▇
  bookings_mean       : 0.116 ▇▇▇
  marketing_spend     : 0.112 ▇▇▇
  gdp_per_capita      : 0.085 ▇▇
  weekend_ratio       : 0.042 ▇
Cross-validation V-weights:
  Split: 84 train / 36 val
  Val RMSPE (best): 16.08
  Val RMSPE range: 16.08 – 16.24 (variación 0.19%)
  V-sensitivity: V tiene impacto mínimo (landscape plano)
  → El resultado está dominado por la serie temporal, no por las covariables
Covariate Balance (DAG-guided):
  Covariable              Tratado  Sintético      SMD
  ------------------------------------------------------
  bookings_mean             153.8      154.0   -0.001     ✓
  bookings_trend              0.2        0.1   +0.545    ⚠️
  weekend_ratio               1.1        1.1   +0.208     ✓
  sessions                 4911.3     4861.4   +0.011     ✓
  gdp_per_capita          24000.0    47059.8   -0.851    ⚠️
  marketing_spend            56.1       55.1   +0.024     ✓
  ⚠️ Desbalance en alguna covariable
```

- **RMSPE:** Desviación de 10.76 booking/dia
- Formado por:
  - Austria: 39,3%
  - Bélgica: 32,9%
  - Lituania: 11,7%
  - Luxemburgo: 5,1%
    - + 4 mercados menores

- **HHI** similar a España (0.281): bien distribuido
- **Covariables:** GDP desbalanceado por la misma razón que España. No tan relevantes como cabría esperar.

- Portugal fue el mercado que empezó más tarde y aquí “solo” disponemos de 30 días post-tratamiento.

Spain (+5%) & UK (+10%)

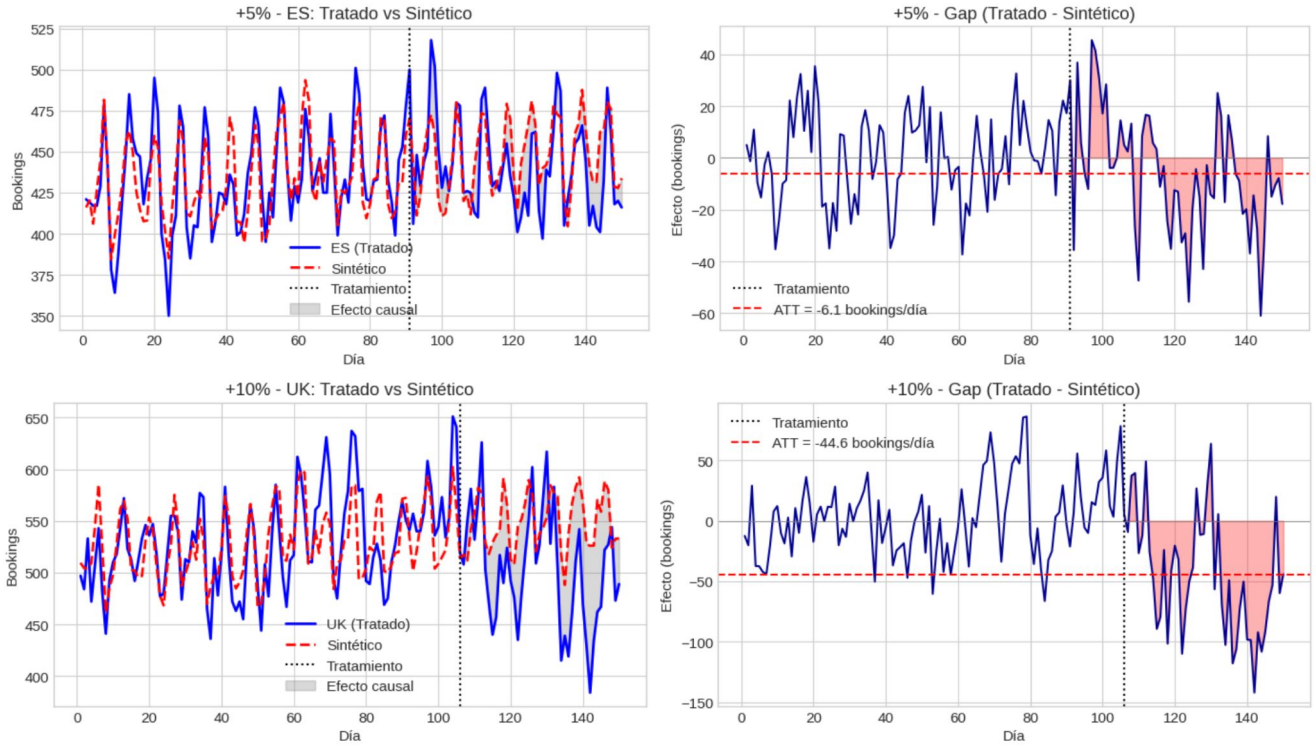

Recordemos la hipótesis:

Si subimos el precio en un % determinado no se denota afectación significativa (positiva o negativa) en las ventas.

- ¿Compensa económicamente la caída en bookings/día?
- ¿Y las guardrail metrics?

Portugal (+15%)

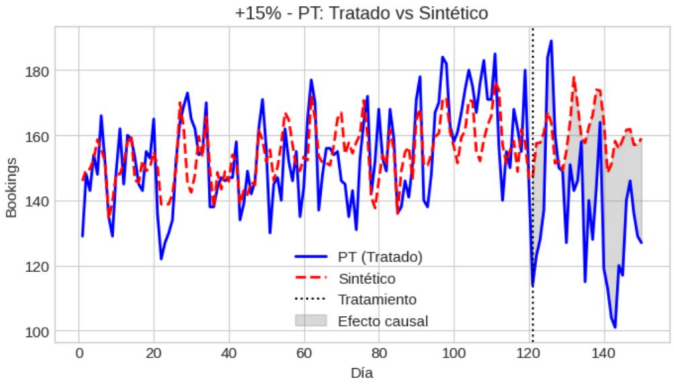

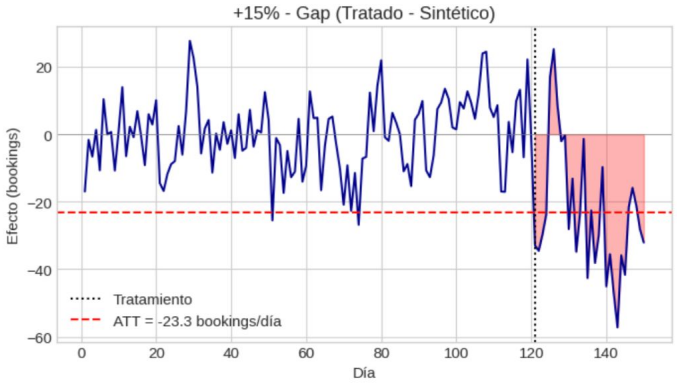

Recordemos la hipótesis:

Si subimos el precio en un % determinado no se denota afectación significativa (positiva o negativa) en las ventas.

- ¿Compensa económicamente la caída en bookings/día?
- ¿Y las guardrail metrics?

Evaluación: Placebo Tests

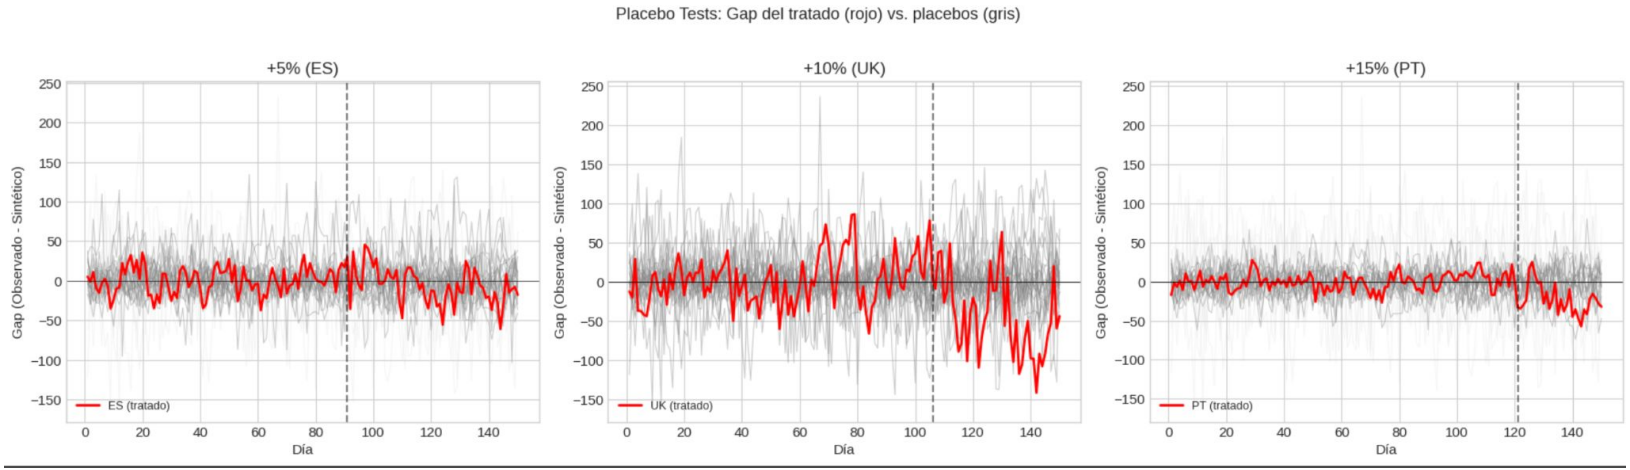

Para evaluar el modelo fingimos que cada mercado de control (Alemania, Bélgica...) tuvo la subida de precios.

Si la subida de precio realmente reduce bookings, la línea roja debería caer por debajo de las grises después del tratamiento.

Evaluación: Placebo Tests

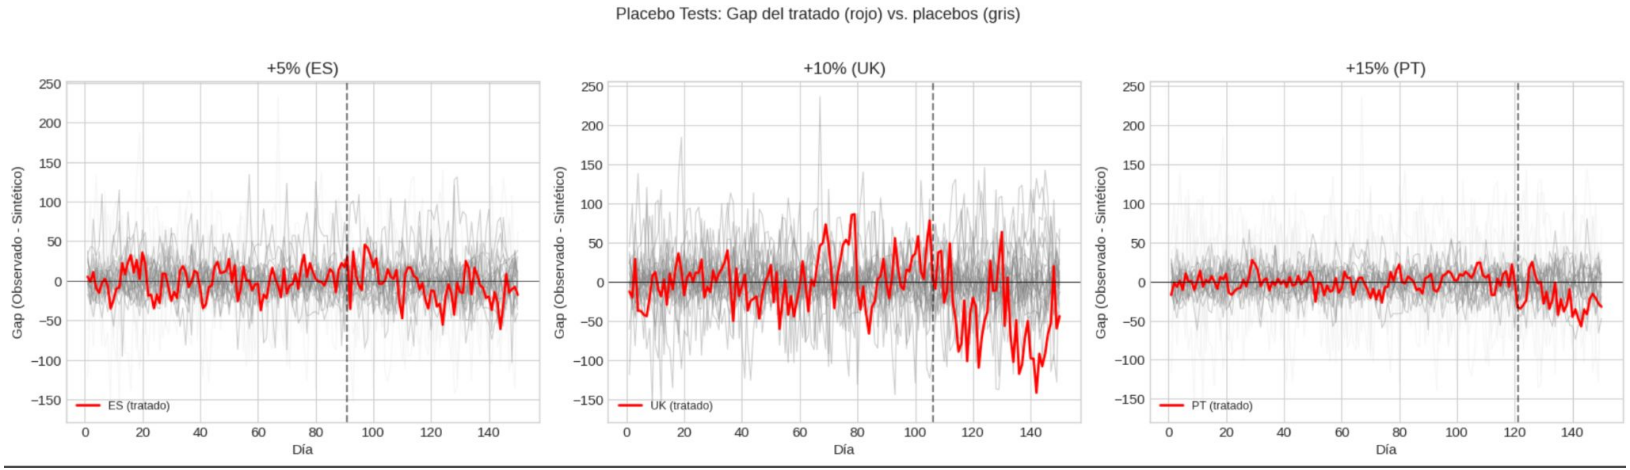

ES (+5%): la roja se mezcla con las grises: **parece no haber un efecto en bookings/día.**
UK (+10%): la roja no se mezcla con las grises: **parece haber un efecto en bookings/dia.**
PT (+15%): la roja no se mezcla con las grises: **parece haber un efecto en bookings/dia.**

Evaluación: Inferencia | Intervalo de confianza + Pre-trends

```
+5% (ES)

  Intervalos de confianza (placebo-based):
    ATT:          -6.1 bookings/día (-1.4%)
    CI 95%: [  -32.1,    19.9] bookings/día
            [  -7.2%,   +4.5%]
    σ(placebo): 13.3
    ⚠ El cero cae dentro del CI → efecto no significativo al 95%

  Test de pre-trends:
    RMSPE pre (tratado): 17.0
    RMSPE pre (placebos): median=18.9, max=75.1
    Rank: 11/24 (percentil 46%)
    ✓ Pre-trends OK: el sintético replica bien al tratado antes del tratamiento
```

```
+15% (PT)

  Intervalos de confianza (placebo-based):
    ATT:      -23.3 bookings/día (-14.5%)
    CI 95%: [  -52.5,     6.0] bookings/día
            [ -32.8%,   +3.8%]
    σ(placebo): 14.9
    ⚠ El cero cae dentro del CI → efecto no significativo al 95%

  Test de pre-trends:
    RMSPE pre (tratado): 10.8
    RMSPE pre (placebos): median=19.8, max=75.6
    Rank: 4/24 (percentil 17%)
    ✓ Pre-trends OK: el sintético replica bien al tratado antes del tratamiento
```

```
+10% (UK)

  Intervalos de confianza (placebo-based):
    ATT:      -44.6 bookings/día (-8.1%)
    CI 95%: [  -73.2,   -15.9] bookings/día
            [ -13.4%,   -2.9%]
    σ(placebo): 14.6
    ✓ El cero NO cae dentro del CI → efecto significativo al 95%

  Test de pre-trends:
    RMSPE pre (tratado): 31.4
    RMSPE pre (placebos): median=19.1, max=76.7
    Rank: 18/24 (percentil 75%)
    ✓ Pre-trends OK: el sintético replica bien al tratado antes del tratamiento
```

Pre-trends: ¿el grupo de control se asemeja a la variante al periodo pre-intervención? Comparamos el error pretratamiento del mercado real contra el de los 23 placebos. Si no está entre los peores, control es fiable (Abadie 2010):

ES (+5%):
Efecto no significativo (CI [-32.1, +19.9] ✅
Pre-trends muy bueno: Rank 11/24, percentil 46% ✅

UK (+10%):
Efecto significativo CI [-73.2, -15.9] ✅
Pre-trends aceptable: Rank 18/24, percentil 75% ⚠

PT (+15%):
Efecto no significativo CI [-52.5, +6.0] ✅
Pre-trends excelente: Rank 4/24, percentil 17% ✅
Cuidado: posible baja potencia estadística en Portugal.

Evaluación: Placebo In-Time

```
======================================================================
PLACEBO IN-TIME: TRATAMIENTO FALSO EN PRE-PERIODO
======================================================================

Si el método funciona, NO deberíamos ver efectos en pre-periodo.

+5% (ES):
 placebo_day  fake_att  rmspe_pre
          36      1.62      17.95
          54      0.68      18.24
          72     10.15      17.46
  ✓ No hay efectos espurios (max |fake ATT|: 10.2 < 2×RMSPE: 33.9)

+10% (UK):
 placebo_day  fake_att  rmspe_pre
          42     10.07      20.16
          63     25.22      21.91
          84     14.91      30.37
  ✓ No hay efectos espurios (max |fake ATT|: 25.2 < 2×RMSPE: 62.8)

+15% (PT):
 placebo_day  fake_att  rmspe_pre
          48      3.15       8.31
          72      7.22       8.79
          96     12.81       9.69
  ✓ No hay efectos espurios (max |fake ATT|: 12.8 < 2×RMSPE: 21.5)
```

Más pruebas:

¿Qué pasa si fingimos que subimos precio en un día donde NO lo hicimos? Si el SCM funciona bien, no debería detectar efecto.

- Para cada mercado probamos 3 fechas falsas de tratamiento (pre-intervención).
- Los "efectos" que detecta (fake ATT) son todos menores que el RMSPE del original, lo cual indica que nuestro modelo funciona. ✅

Resultados

```
+5% (ES):
  Baseline pre-tratamiento: 433 bookings/día
  Contrafactual (sintético): 447 bookings/día
  ATT: -6.1 ± 23.1 bookings/día
  Cambio en precio (realizado): +5.0%
  Cambio en bookings (causal): -1.4%
  Elasticidad precio-demanda: -0.27

+10% (UK):
  Baseline pre-tratamiento: 530 bookings/día
  Contrafactual (sintético): 548 bookings/día
  ATT: -44.6 ± 49.5 bookings/día
  Cambio en precio (realizado): +10.0%
  Cambio en bookings (causal): -8.1%
  Elasticidad precio-demanda: -0.81

+15% (PT):
  Baseline pre-tratamiento: 154 bookings/día
  Contrafactual (sintético): 160 bookings/día
  ATT: -23.3 ± 19.0 bookings/día
  Cambio en precio (realizado): +15.0%
  Cambio en bookings (causal): -14.5%
  Elasticidad precio-demanda: -0.97
```

ES (+5%)

- Desciende bookings un 1.4%
- Pricing: +5%

UK (+10%)

- Desciende bookings un 8.1%
- Pricing: +10%

PT (+15%)

- Desciende bookings un 14.5%
- Pricing: +15%

Resultados

```
+5% (ES):
  Precio: 89 EUR → 93 EUR (+5%)
  Bookings observados:     441/día
  Bookings contrafactual:  447/día (sintético)
  Revenue observado:       41,218 EUR/día
  Revenue contrafactual:   39,798 EUR/día
  Delta Revenue:           +1,419 EUR/día (+3.6%)
  Impacto total (60 días): +85,153 EUR

+10% (UK):
  Precio: 89 EUR → 98 EUR (+10%)
  Bookings observados:     504/día
  Bookings contrafactual:  548/día (sintético)
  Revenue observado:       49,313 EUR/día
  Revenue contrafactual:   48,797 EUR/día
  Delta Revenue:           +516 EUR/día (+1.1%)
  Impacto total (45 días): +23,233 EUR

+15% (PT):
  Precio: 89 EUR → 102 EUR (+15%)
  Bookings observados:     137/día
  Bookings contrafactual:  160/día (sintético)
  Revenue observado:       13,995 EUR/día
  Revenue contrafactual:   14,239 EUR/día
  Delta Revenue:           -244 EUR/día (-1.7%)
  Impacto total (30 días): -7,334 EUR
```

Resultados (extrapolacion)

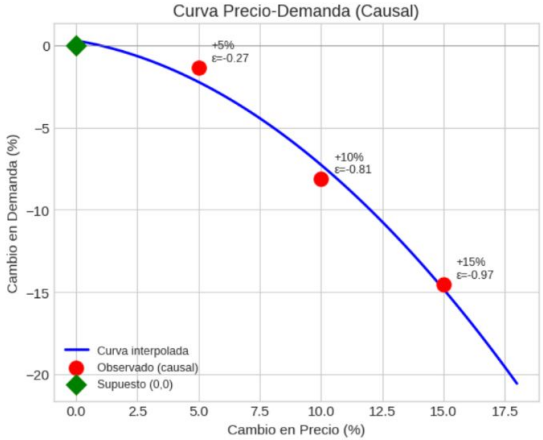

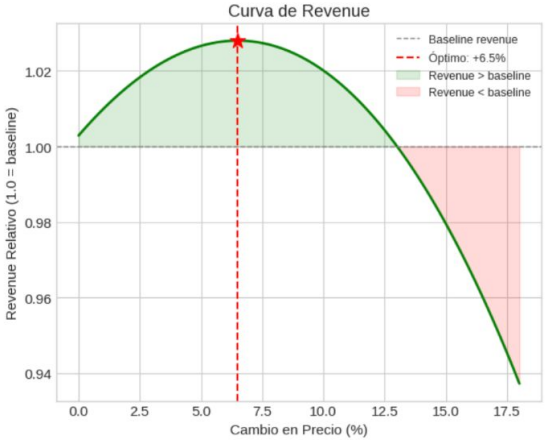

- **Eje Y:** Cambio de demanda basada en nuestros datos.
- **Eje Y:** Cambio de precio.
- **ES:** que esté por encima de la línea azul implica que no afecta en ese mercado ese cambio.
- **UK:** Está por debajo (duele).
- **PT:** Está ahí ahí... al límite.

- **Eje Y:** Revenue relativo. Por encima ganas, por debajo pierdes.
- **Eje X:** Cambio de precio.
- **Punto óptimo:** óptimo en +6.5% en pricing.
- **Break-even:** a +13% el revenue es exactamente igual que si no hubieras tocado el precio. Por encima de +13%, estás peor que no haciendo nada (contrafactual).

Resultados (guardrails: descriptivas)

```
+5% (ES):
----------------------------------------
  LTV (EUR): -0.4% ✓ OK
  Churn Rate: +0.9% ✓ OK
  CR Checkout→Sale: -1.0% ✓ OK

+10% (UK):
----------------------------------------
  LTV (EUR): -0.0% ✓ OK
  Churn Rate: +0.3% ✓ OK
  CR Checkout→Sale: -2.7% ✓ OK

+15% (PT):
----------------------------------------
  LTV (EUR): +0.1% ✓ OK
  Churn Rate: -3.8% ✓ OK
  CR Checkout→Sale: -2.2% ✓ OK
```

Resultados (factual & contrafactual)

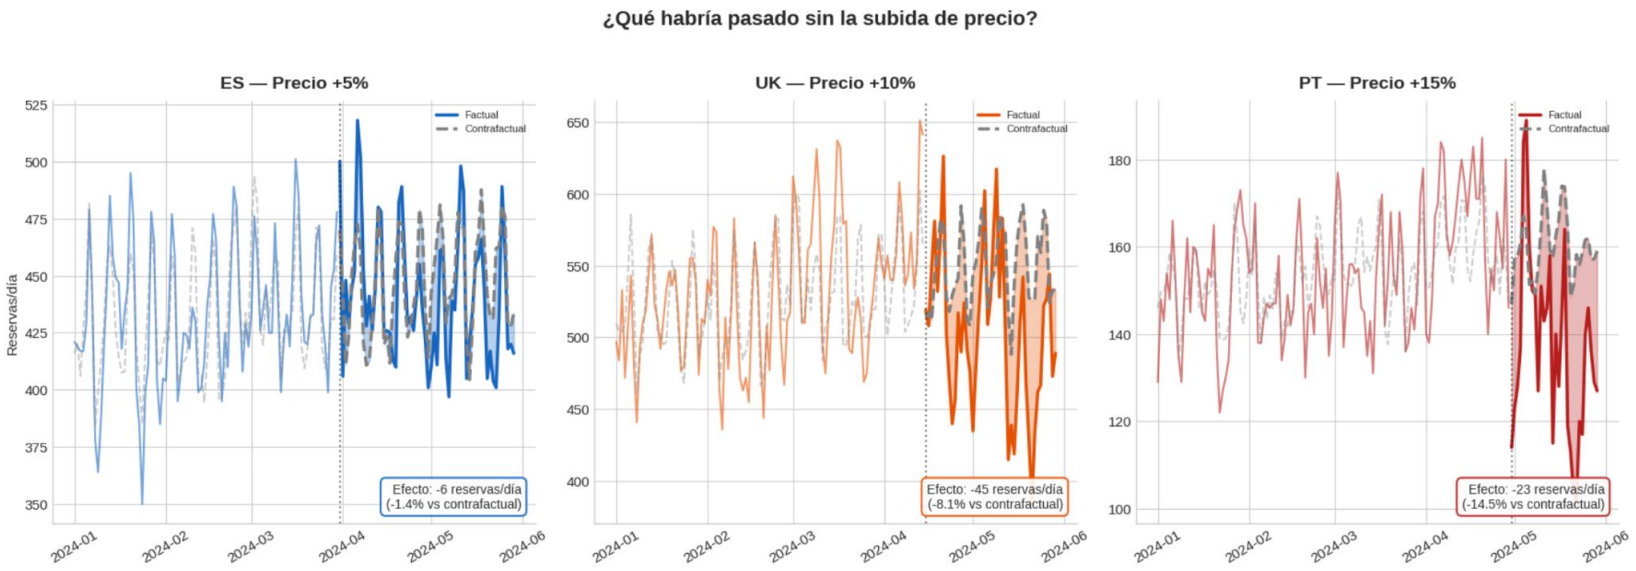

Resultados, recomendación y aprendizaje

```
 +5% (ES): ATT =   -6.1 book/día ( -1.4%)    n.s.   |
+10% (UK): ATT =  -44.6 book/día ( -8.1%)  ✓ sig.   |
+15% (PT): ATT =  -23.3 book/día (-14.5%)    n.s.   |

sig. = CI 95% excluye cero; n.s. = no significativo al 95%
```

```
Incremento óptimo:  +6.5%
Precio óptimo:      94.78 EUR
Efecto en revenue:  +2.8% vs baseline

RECOMENDACIÓN:
Subidas hasta +6% AUMENTAN revenue.
Por encima de +13% se DESTRUYE revenue.
```

Identification & estimation framework decision

Autor
Ubaldo Hervás

Fecha
marzo 2026

1. ¿Puedes aleatorizar?

Y

Randomización

1. AB/n test
2. AB Test
3. Switchback test
4. Holdout test
5. Cluster RCT

1. ¿Puedes aleatorizar?

Y

Randomización

1. AB/n test
2. AB Test
3. Switchback test
4. Holdout test
5. Cluster RCT

N

2. ¿El tratamiento se asigna al cruzar un umbral numérico?

Y

RDD

1. LLR
2. Polynomial
3. Kernel-based

1. ¿Puedes aleatorizar?

Y

Randomización

1. AB/n test
2. AB Test
3. Switchback test
4. Holdout test
5. Cluster RCT

N

2. ¿El tratamiento se asigna al cruzar un umbral numérico?

Y

RDD

1. LLR
2. Polynomial
3. Kernel-based

N

3. ¿Existe un instrumento válido (Relevance, Exogeneity, Exclusion Restriction)?

Y

IV

1. 2SLS
2. LIML
3. Arellano Bond
4. DML-IV

1. ¿Puedes aleatorizar?

Y

Randomización

1. AB/n test
2. AB Test
3. Switchback test
4. Holdout test
5. Cluster RCT

N

2. ¿El tratamiento se asigna al cruzar un umbral numérico?

Y

RDD

1. LLR
2. Polynomial
3. Kernel-based

N

3. ¿Existe un instrumento válido (Relevance, Exogeneity, Exclusion Restriction)?

Y

IV

1. 2SLS
2. LIML
3. Arellano Bond
4. DML-IV

N

4. ¿Hay unidades que no han recibido la intervención (mismo periodo)?

N

Interrupted Time Series

1. ITSA
2. BSTS

1. ¿Puedes aleatorizar?

- **Y** → **Randomización**
  1. AB/n test
  2. AB Test
  3. Switchback test
  4. Holdout test
  5. Cluster RCT
- **N** → **2. ¿El tratamiento se asigna al cruzar un umbral numérico?**

2. ¿El tratamiento se asigna al cruzar un umbral numérico?

- **Y** → **RDD**
  1. LLR
  2. Polynomial
  3. Kernel-based
- **N** → **3. ¿Existe un instrumento válido (Relevance, Exogeneity, Exclusion Restriction)?**

3. ¿Existe un instrumento válido (Relevance, Exogeneity, Exclusion Restriction)?

- **Y** → **IV**
  1. 2SLS
  2. LIML
  3. Arellano Bond
  4. DML-IV
- **N** → **4. ¿Hay unidades que no han recibido la intervención (mismo periodo)?**

4. ¿Hay unidades que no han recibido la intervención (mismo periodo)?

- **Y** → **5. ¿Existe un conjunto de variables observables que satisfaga backdoor criterion?**
- **N** → **Interrupted Time Series**
  1. ITSA
  2. BSTS

5. ¿Existe un conjunto de variables observables que satisfaga backdoor criterion?

- **N** → **Comparative Counterfactuals***
  1. DiD
  2. SCM
  3. ASCM
  4. BSTS
  5. DID staggered

*Estos métodos tienen su lógica identificadora propia

1. ¿Puedes aleatorizar?

- **Y** → **Randomización**
  1. AB/n test
  2. AB Test
  3. Switchback test
  4. Holdout test
  5. Cluster RCT
- **N** → **2. ¿El tratamiento se asigna al cruzar un umbral numérico?**

2. ¿El tratamiento se asigna al cruzar un umbral numérico?

- **Y** → **RDD**
  1. LLR
  2. Polynomial
  3. Kernel-based
- **N** → **3. ¿Existe un instrumento válido (Relevance, Exogeneity, Exclusion Restriction)?**

3. ¿Existe un instrumento válido (Relevance, Exogeneity, Exclusion Restriction)?

- **Y** → **IV**
  1. 2SLS
  2. LIML
  3. Arellano Bond
  4. DML-IV
- **N** → **4. ¿Hay unidades que no han recibido la intervención (mismo periodo)?**

4. ¿Hay unidades que no han recibido la intervención (mismo periodo)?

- **Y** → **5. ¿Existe un conjunto de variables observables que satisfaga backdoor criterion?**
- **N** → **Interrupted Time Series**
  1. ITSA
  2. BSTS

5. ¿Existe un conjunto de variables observables que satisfaga backdoor criterion?

- **Y** → **Selection on Observables**
  ¿El tratamiento se repite y sus efectos pasados cambian quién recibe el tratamiento futuro?
  - **Y**
    1. G-Computation
    2. LTMLE
    3. MSM+IPTW
  - **N**
    1. DML
    2. PSM
    3. AIPW
- **N** → **Comparative Counterfactuals***
  1. DiD
  2. SCM
  3. ASCM
  4. BSTS
  5. DID staggered

*Estos métodos tienen su lógica identificadora propia

1. ¿Puedes aleatorizar?

- **Y** → **Randomización**
  1. AB/n test
  2. AB Test
  3. Switchback test
  4. Holdout test
  5. Cluster RCT
- **N** → **2. ¿El tratamiento se asigna al cruzar un umbral numérico?**

2. ¿El tratamiento se asigna al cruzar un umbral numérico?

- **Y** → **RDD**
  1. LLR
  2. Polynomial
  3. Kernel-based
- **N** → **3. ¿Existe un instrumento válido (Relevance, Exogeneity, Exclusion Restriction)?**

3. ¿Existe un instrumento válido (Relevance, Exogeneity, Exclusion Restriction)?

- **Y** → **IV**
  1. 2SLS
  2. LIML
  3. Arellano Bond
  4. DML-IV
- **N** → **4. ¿Hay unidades que no han recibido la intervención (mismo periodo)?**

4. ¿Hay unidades que no han recibido la intervención (mismo periodo)?

- **Y** → **5. ¿Existe un conjunto de variables observables que satisfaga backdoor criterion?**
- **N** → **Interrupted Time Series**
  1. ITSA
  2. BSTS

5. ¿Existe un conjunto de variables observables que satisfaga backdoor criterion?

- **Y** → **Selection on Observables**
  ¿El tratamiento se repite y sus efectos pasados cambian quién recibe el tratamiento futuro?
  - **Y**
    1. G-Computation
    2. LTMLE
    3. MSM+IPTW
  - **N**
    1. DML
    2. PSM
    3. AIPW
- **N** → **Comparative Counterfactuals***
  1. DiD
  2. SCM
  3. ASCM
  4. BSTS
  5. DID staggered

*Estos métodos tienen su lógica identificadora propia

Asunciones menos fuertes

↓

Asunciones más fuertes

1. ¿Puedes aleatorizar?

- **Y** → **Randomización**
  1. AB/n test
  2. AB Test
  3. Switchback test
  4. Holdout test
  5. Cluster RCT
- **N** → **2. ¿El tratamiento se asigna al cruzar un umbral numérico?**

2. ¿El tratamiento se asigna al cruzar un umbral numérico?

- **Y** → **RDD**
  1. LLR
  2. Polynomial
  3. Kernel-based
- **N** → **3. ¿Existe un instrumento válido (Relevance, Exogeneity, Exclusion Restriction)?**

3. ¿Existe un instrumento válido (Relevance, Exogeneity, Exclusion Restriction)?

- **Y** → **IV**
  1. 2SLS
  2. LIML
  3. Arellano Bond
  4. DML-IV
- **N** → **4. ¿Hay unidades que no han recibido la intervención (mismo periodo)?**

4. ¿Hay unidades que no han recibido la intervención (mismo periodo)?

- **Y** → **5. ¿Existe un conjunto de variables observables que satisfaga backdoor criterion?**
- **N** → **Interrupted Time Series**
  1. ITSA
  2. BSTS

5. ¿Existe un conjunto de variables observables que satisfaga backdoor criterion?

- **Y** → **Selection on Observables**
  ¿El tratamiento se repite y sus efectos pasados cambian quién recibe el tratamiento futuro?
  - **Y**
    1. G-Computation
    2. LTMLE
    3. MSM+IPTW
  - **N**
    1. DML
    2. PSM
    3. AIPW
- **N** → **Comparative Counterfactuals***
  1. DiD
  2. SCM
  3. ASCM
  4. BSTS
  5. DID staggered

*Estos métodos tienen su lógica identificadora propia

¡Gracias!